Asignación Robusta de Portafolios en el Mercado NUAM: Una Extensión de la Paridad de Riesgo Jerárquica basada en Autoencoders Variacionales

Gonzalo Ramírez-Carrillo, Óscar Carrillo-García, Smaily Arenas-Contreras y Juan M. Delgado

Facultad de Economía, Universidad del Rosario

Resumen

Este estudio propone una extensión a la metodología de Paridad de Riesgo Jerárquica mediante el uso de Autoencoders Variacionales, con el fin de extraer representaciones latentes no lineales de la estructura de dependencia en un conjunto de 53 acciones del índice MSCI NUAM (Chile, Colombia y Perú), durante el período 2019–2026. Esta propuesta busca mejorar la asignación de activos y mitigar las limitaciones de los modelos clásicos de optimización. Los hallazgos fuera de muestran que el modelo propuesto supera al HRP clásico, incrementando el *Sharpe Ratio* de 0.4938 a 0.5210 y el Retorno Total de 0.7107 a 0.7312. Adicionalmente, registra una menor Desviación Estándar Anualizada y una reducción en la Rotación Promedio del Portafolio. La combinación de métodos aprendizaje profundo probabilístico junto a la asignación jerárquica permite estrategias de inversión con mejor desempeño ajustado por riesgo en mercados de capitales integrados.

Palabras clave: Selección de Portafolios; Mercados Financieros Internacionales; Pronóstico y Simulación Financiera; Redes Neuronales; Técnicas Computacionales.

Abstract

This study proposes an extension to the Hierarchical Risk Parity (HRP) methodology through the integration of Variational Autoencoders (VAEs) to extract non-linear latent representations of the dependence structure among a set of 53 stocks included in the MSCI NUAM Index (Chile, Colombia, and Peru) over the 2019–2026 period. The proposed approach aims to improve asset allocation and address some of the limitations of traditional portfolio optimization models. Out-of-sample results show that the proposed model outperforms the classical HRP approach, increasing the Sharpe ratio from 0.4938 to 0.5210 and total return from 0.7107 to 0.7312. In addition, the model achieves a lower annualized standard deviation and reduced average portfolio turnover. The combination of probabilistic deep learning techniques and hierarchical allocation methods yields investment strategies with improved risk-adjusted performance in integrated capital markets.

Keywords: Portfolio Choice; International Financial Markets; Financial Forecasting and Simulation; Neural Networks; Computational Techniques.

JEL Classification: G11, G15, G17, C45, C63.

1. Introducción

El mercado NUAM representa un paso significativo en la integración de los mercados de capitales en América Latina. Constituye un holding regional que integra las bolsas de valores de Santiago de Chile, Colombia y Lima (Ruiz & Alvarado, 2024). Esta integración tiene como objetivo generar un mercado más eficiente, accesible, líquido y con atractivo a nivel global (Ruiz & Alvarado, 2024), ampliando las posibilidades de diversificación para los diferentes participantes del mercado de capitales. A diferencia de iniciativas previas como el Mercado Integrado Latinoamericano (MILA), cuya integración resultó limitada por barreras tributarias y regulatorias que mantuvieron la fragmentación de las plazas locales (Montoya, 2024), NUAM plantea una combinación de carácter estructural fundamentada en la unificación de la infraestructura tecnológica de negociación y la estandarización de sus procesos y condiciones operativas (Ortiz Mayorga, 2025).

Aunque la integración incrementa la cantidad de activos disponibles, también plantea desafíos estructurales, como la armonización normativa, la gestión operativa de múltiples divisas y la interoperabilidad tecnológica de la infraestructura común (Ortiz Mayorga, 2025). Estas particularidades operativas introducen anomalías en la formación de precios, un escenario que pone de manifiesto las limitaciones de enfoques tradicionales de asignación de activos, como la Teoría Moderna de Portafolio (MPT) de Harry Markowitz (1952). Si bien la MPT es un pilar fundamental de las finanzas, su supuesto de parámetros estáticos puede resultar insuficiente para capturar las condiciones dinámicas, las dependencias no lineales y el riesgo de contagio propios de un entorno regional en consolidación (Kolm et al., 2014).

Específicamente, las deficiencias de la MPT se manifiestan en una marcada sensibilidad ante errores de estimación, lo cual tiende a generar asignaciones inestables (Mena Valencia, 2023). A esta vulnerabilidad se añade la ausencia de mecanismos intrínsecos para controlar la distribución del riesgo que puede derivar en portafolios concentrados en pocos activos (Ciciretti & Pallotta, 2024; Palit & Prybutok, 2024). Adicionalmente, la inestabilidad numérica vinculada a la inversión de la matriz de covarianza en escenarios de alta dimensionalidad compromete el desempeño fuera de muestra (Lopez de Prado, 2016).

Frente a estas restricciones, surge el modelo de Paridad de Riesgo Jerárquica (*Hierarchical Risk Parity, HRP*). Propuesto originalmente por Marcos López de Prado (2016), este enfoque utiliza conceptos de la teoría de grafos y el aprendizaje no supervisado para mitigar la denominada maldición de Markowitz. Esta metodología distribuye los activos mediante una estructura jerárquica basada en el análisis de clústeres, lo que permite construir portafolios robustos sin requerir la inversión de la matriz de covarianza. Al prescindir de esta operación algebraica, crítica en el modelo de Markowitz, el método propuesto por López de Prado logra una distribución de pesos más estable y un desempeño superior en pruebas fuera de muestra (Lopez de Prado, 2016; Sen & Dutta, 2022).

El modelo HRP ha sido utilizado en el estudio de empresas de Chile, Colombia y Perú listadas como ADR en la Bolsa de Nueva York (NYSE) (Urrego, 2024), un análisis donde se

destaca la capacidad del algoritmo para tratar la inestabilidad propia de estos mercados, identificando estructuras donde las empresas estudiadas se agrupan naturalmente, respetando fronteras industriales e internacionales. Además, en pruebas dentro de la muestra, esta metodología supera al modelo tradicional de media-varianza en términos de retorno ajustado por riesgo (Urrego, 2024).

A pesar de sus ventajas frente al modelo clásico de optimización de portafolio, la literatura identifica varias limitaciones. Se señala que el método HRP no determina de manera automática el número óptimo de clústeres (Katranci & Kundakci, 2026). Otra limitación es que el modelo asume una distribución normal de los retornos, lo cual no siempre se cumple en la práctica (Katranci & Kundakci, 2026). Además, su desempeño depende de matrices históricas cuya validez puede verse comprometida en periodos de alta volatilidad o ante cambios en el régimen de mercado (Bajpai et al., 2023; Deković & Šimović, 2025).

Para mitigar la vulnerabilidad de las matrices históricas ante escenarios de alta volatilidad y la no normalidad de los retornos financieros, esta investigación propone una extensión original del modelo HRP clásico mediante la integración de Autoencoders *Variacionales (VAE),* incorporados como una etapa de preprocesamiento previa a la construcción del portafolio (Borovkova & van den Oever, 2022; Duan et al., 2022). Esta arquitectura de aprendizaje profundo permite modelar estructuras complejas y dependencias no lineales que los enfoques basados exclusivamente en correlaciones tradicionales no logran representar adecuadamente (Duan et al., 2022). Al incorporar información contenida en el espacio latente de los retornos, se plantea que la metodología propuesta puede fortalecer la estabilidad del proceso de agrupamiento jerárquico y reducir la sensibilidad de las asignaciones a perturbaciones en los datos de entrada, favoreciendo así un desempeño más consistente fuera de muestra.

La contribución de esta investigación es triple. En primer lugar, propone una innovación técnica al integrar filtros no lineales (VAE) en el flujo de la metodología HRP; en segundo lugar, aporta evidencia empírica inédita sobre el comportamiento del mercado NUAM mediante el análisis de una muestra de 53 acciones; y, por último, ofrece una metodología de asignación de portafolios adaptada a entornos de integración bursátil regional.

El resto del artículo se estructura de la siguiente manera: la Sección 2 aborda el marco teórico y la revisión de la literatura; la Sección 3, el marco metodológico; la Sección 4, el diseño empírico; la Sección 5, los datos; la Sección 6, los resultados; y, finalmente, la Sección 7 expone las conclusiones del estudio.

2. Marco Teórico y Revisión de la Literatura

La Teoría Moderna de Portafolio (MPT), desarrollada originalmente por Markowitz (1952) proporciona un marco formal y cuantitativo para la construcción de portafolios. Este enfoque modela las decisiones de inversión como un problema de optimización que equilibra los rendimientos esperados y el riesgo. En este modelo, la incertidumbre se representa mediante la

varianza de los rendimientos de los activos, mientras que el retorno esperado del portafolio se calcula como una combinación lineal de las ponderaciones de cada activo. El objetivo central de la MPT consiste en dar solución al siguiente problema de optimización:

$$\min_{w} \; w^{T}\Sigma w \;\; \text{s.a.} \;\; w^{T}\mu = \mu_{p}, \sum_{i=1}^{n} w_{i} = 1 \qquad (1)$$

Donde w representa el vector de pesos de los activos en el portafolio, Σ es la matriz de covarianza de los retornos y μ es el vector de retornos esperados. Este planteamiento permite identificar el portafolio de mínima varianza para un nivel determinado de rendimiento esperado, incorporando explícitamente la estructura de dependencia entre los activos a través de sus covarianzas. La solución analítica de este sistema se expresa de la siguiente forma:

$$w = \frac{\Sigma^{-1}\mu}{1^{T}\Sigma^{-1}\mu} \qquad (2)$$

A partir de esta solución se deriva la frontera eficiente, definida como el conjunto de portafolios que ofrecen el mayor rendimiento esperado para un nivel de riesgo determinado (Markowitz, 1952). Sin embargo, la naturaleza teórica de este modelo contrasta con las dificultades prácticas de su implementación empírica, especialmente en contextos donde las condiciones de mercado son dinámicas o estructuralmente complejas (Kolm et al., 2014).

En este sentido, una de las limitaciones más persistentes de la MPT es su alta sensibilidad a los errores de estimación (Lopez de Prado, 2016). En particular, las desviaciones en la predicción de los rendimientos esperados suelen inducir asignaciones de portafolio inestables y altamente concentradas, un fenómeno ampliamente documentado tanto en estudios empíricos como en aplicaciones del mundo real (Mena Valencia, 2023). Por otra parte, el requisito de invertir la matriz de covarianza suele provocar problemas de inestabilidad numérica, especialmente en contextos de alta dimensionalidad; esta condición conduce a la construcción de portafolios con sesgo de optimización y con un bajo desempeño fuera de la muestra (Lopez de Prado, 2016).

Adicionalmente, la MPT presenta limitaciones para gestionar la distribución interna del riesgo entre los activos (Palit & Prybutok, 2024). Aunque el modelo optimiza el rendimiento por unidad de varianza total, en la práctica suele producir portafolios donde unos pocos activos con baja volatilidad dominan la asignación; esta condición disminuye la efectividad de la diversificación e induce concentraciones de riesgo (Ciciretti & Pallotta, 2024).

Dadas las anteriores limitaciones, se han desarrollado diversas extensiones del modelo clásico de media-varianza, entre las que se incluyen la optimización robusta, los métodos bayesianos, los estimadores de contracción y el modelo de Black–Litterman (Kaczmarek & Perez, 2022). Estas aproximaciones buscan mejorar la estabilidad en la estimación de parámetros o incorporar información adicional como las expectativas de los inversionistas.

No obstante, estas metodologías continúan fundamentándose en el marco clásico de media-varianza y, por consiguiente, heredan sus limitaciones esenciales (Lopez de Prado, 2016). Particularmente el desempeño del modelo puede estar comprometido en entornos caracterizados por alta volatilidad, distribuciones no gaussianas o quiebres estructurales; condiciones que resultan recurrentes en mercados emergentes o en procesos de integración financiera.

2.1 Paridad de Riesgo Jerárquica (HRP)

La formalización de la Paridad de Riesgo Jerárquica (HRP) opera sobre la información contenida en la matriz de covarianza, sustituyendo la optimización tradicional por un proceso secuencial fundamentado en la teoría de grafos y el aprendizaje no supervisado (Lopez de Prado, 2016). Al prescindir matemáticamente de la inversión de la matriz de covarianza, esta metodología mitiga restricciones críticas del modelo clásico, tales como la inestabilidad numérica, la hipersensibilidad a los errores de estimación y la concentración excesiva de capital en unos pocos activos dominantes (Lopez de Prado, 2016; Palit & Prybutok, 2024).

La base del modelo HRP radica en la identificación de estructuras de dependencia, donde los activos no son tratados de manera aislada, sino que se agrupan en conglomerados que comparten factores de riesgo, dinámicas sectoriales o exposiciones macroeconómicas similares reflejadas en sus precios. Esta propiedad resulta especialmente conveniente al analizar mercados integrados como el NUAM. Al consolidar plazas bursátiles con características diferenciadas en términos de liquidez, profundidad financiera y composición sectorial, el modelo HRP permite identificar estructuras de codependencia a partir de los patrones empíricos observados en los datos, superando los sesgos de los criterios de agrupación geográfica o industrial tradicionales.

2.1.1 Algoritmo HRP

El algoritmo HRP se divide en tres etapas secuenciales: agrupamiento jerárquico *(Tree Clustering),* quasi-diagonalización *(Quasi-Diagonalization)* y bisección recursiva *(Recursive Bisection)* (Lopez de Prado, 2016; Urrego, 2024). Estas etapas permiten, en primer lugar, identificar la estructura de dependencia entre los activos; en segundo lugar, reorganizar la matriz de covarianza de acuerdo con dicha estructura; y, en tercer lugar, asignar los pesos del portafolio en función del riesgo agregado de cada grupo. A diferencia del enfoque clásico de media-varianza, este procedimiento sustituye la optimización global simultánea por una serie de decisiones de asignación local, estructuradas a partir de las relaciones de dependencia mutua entre los activos.

La primera etapa corresponde al agrupamiento jerárquico aglomerativo. Este procedimiento busca formar grupos de activos con comportamientos financieros similares a partir de las relaciones de dependencia observadas en sus retornos (Sen & Dutta, 2022). El algoritmo comienza considerando cada activo como un grupo (clúster) individual y, posteriormente, fusiona de manera iterativa aquellos activos o grupos que presentan una mayor similitud, hasta conformar una estructura jerárquica completa del universo de inversión (Lu & Uddin, 2024; Urrego, 2024).

Para construir la estructura de agrupamiento, se parte de una matriz de distancias construida a partir de la matriz de correlaciones de los retornos de los activos (Prado, 2018). Esta transformación permite convertir el grado de asociación lineal entre los retornos de los activos en una métrica de distancia, de modo que aquellos con una mayor asociación se ubiquen más próximos dentro de la estructura jerárquica. La distancia entre dos activos puede expresarse como:

$$d_{ij} = \sqrt{\frac{1 - \rho_{ij}}{2}} \qquad (3)$$

Donde d_{ij} representa la distancia entre los activos (i) y (j), mientras que (ρ_{ij}) corresponde a la correlación entre sus retornos. Los activos con correlacionados altas presentan distancias menores, mientras que aquellos con comportamientos menos similares aparecen más alejados dentro de la jerarquía.

La construcción de esta jerarquía requiere, además, seleccionar un método de enlace (*linkage*), entre los que se destacan el enlace simple, el enlace completo, el enlace promedio y el método de enlace de Ward (Habib et al., 2016; Yokokawa et al., 2022). Estos métodos determinan el criterio utilizado para medir la cercanía entre clústeres durante el proceso de agrupamiento. El resultado del algoritmo jerárquico suele representarse mediante un gráfica conocida como dendrograma, la cual permite visualizar cómo los activos se agrupan progresivamente de acuerdo con su grado de similitud (Li et al., 2024).

Una vez establecida la estructura jerárquica, la segunda etapa del algoritmo HRP corresponde a la quasi-diagonalización de la matriz de covarianza (Prado, 2018). Este procedimiento consiste en reorganizar las filas y columnas de la matriz de acuerdo con el orden obtenido en el agrupamiento jerárquico. Su objetivo es hacer más visible la estructura de dependencia entre los activos. En particular, los activos con mayor afinidad tienden a ubicarse próximos a la diagonal principal, mientras que aquellos menos relacionados se sitúan en posiciones más alejadas (Sen & Dutta, 2022). Matemáticamente, esta reorganización puede expresarse como:

$$C^{*} = PCP^{T} \qquad (4)$$

(C*) representa la matriz quasi-diagonalizada, C corresponde a la matriz de covarianza original de dimensión (N x N) y (P) es la matriz de permutación derivada del orden jerárquico obtenido mediante el algoritmo de agrupamiento aglomerativo. De este modo, la quasi-diagonalización permite que la matriz de covarianza refleje de manera ordenada los grupos identificados en la etapa anterior.

La tercera etapa corresponde a la bisección recursiva (*Recursive Bisection*) (Prado, 2018). En esta fase se determinan las ponderaciones finales de cada activo dentro del portafolio mediante una asignación descendente a través de la jerarquía construida. El conjunto ordenado de activos se

divide recursivamente en dos subconjuntos adyacentes y, para cada partición, se calcula la varianza agregada de ambos grupos. A partir de esta comparación, el algoritmo asigna un mayor peso relativo al subconjunto con menor varianza y reduce la exposición al que concentra un mayor nivel de riesgo (Salas-Molina et al., 2025). La asignación puede expresarse de la siguiente manera:

$$\alpha = \frac{\sigma_R^2}{\sigma_L^2 + \sigma_R^2} \qquad (5)$$
$$w_L = \alpha \cdot w_s, \qquad w_R = (1 - \alpha) \cdot w_s$$

Donde (σ_L^2) y (σ_R^2) representan las varianzas de los subconjuntos izquierdo y derecho, respectivamente, mientras que (w_s) corresponde al peso total del subconjunto antes de la división. Como resultado, se genera un portafolio donde los pesos de cada activo se encuentran acotados entre cero y uno y la sumas de estos es igual a uno.

La asignación de las participaciones para cada uno de los activos, no se realiza de manera aislada, sino que se tiene en cuenta la estructura jerárquica previamente identificada. De esta forma, el enfoque HRP distribuye el riesgo primero entre grupos de activos y luego dentro de cada grupo, lo que permite reducir la concentración excesiva en activos individuales y construir una diversificación más coherente a nivel de clústeres (Prado, 2018). Lo anterior, resulta relevante para el análisis del mercado NUAM, puesto que permite evaluar la integración financiera regional a partir de las relaciones efectivas entre los diferentes activos.

2.2 Brechas de Investigación y Contribución del Estudio

Tras su formulación inicial, el modelo HRP ha servido como punto de partida para nuevas propuestas que buscan fortalecer la asignación de activos mediante herramientas matemáticas más robustas y estructuras jerárquicas alternativas.

Una línea de desarrollo se concentra en mejorar la eficiencia computacional y la forma en cómo se utiliza la información contenida en la matriz de covarianza. En este grupo se encuentra el estudio de Mograby (2025), el cual emplea estructuras de grafos jerárquicos y el método del complemento de Schur para reducir la complejidad computacional, manteniendo la información completa de la covarianza. De manera similar, Cotton (2024) utiliza matrices de subcovarianza basadas en el complemento de Schur para unificar enfoques heurísticos con la optimización de varianza mínima, corrigiendo los problemas de sobreponderación y subponderación.

Otra vertiente examina el diseño de arquitecturas topológicas alternativas para la gestión de riesgos extremos. En este campo, Ciciretti & Pallotta (2024) utiliza la teoría de grafos y árboles de expansión mínima para capturar relaciones de distribución centralizada entre activos, logrando portafolios menos concentrados frente a los métodos tradicionales. Trabajos para la gestión de riesgos extremos, como el de Paolella et al. (2025) emplea distribuciones elípticas, el algoritmo de Esperanza-Maximización (EM) y el *Expected Shortfall* para generar portafolios más robustos y que tengan menor rotación durante periodos de estrés financiero. Katranci y Kundakci (2026)

proponen integrar a la metodología HRP técnicas multicriterio, MEREC y WEDBA, para determinar el número óptimo de clústeres, evaluar el desempeño financiero de los activos dentro de cada grupo y construir portafolios con una mejor distribución del riesgo.

En términos de extensiones basadas en aprendizaje automático, el estudio de Gaggero et al. (2024) integra el algoritmo HRP con el método de *Logic Learning Machine* (LLM) con el propósito de incrementar la explicabilidad e interpretabilidad de la estrategia. Esta combinación permite superar la vaguedad de los modelos de caja negra. Kang y Tian (2025) proponen un método de aprendizaje de dos niveles, el cual combina el aprendizaje por refuerzo y un HRP Bayesiano para ajustar las exposiciones de los activos según las condiciones del mercado. El artículo de Rodriguez Dominguez (2023) utiliza redes neuronales y diferenciación adyacente automática con el fin de lograr la máxima diversificación ante regímenes no estacionarios. Lewis (2023) emplea una estructura de árbol para reducir el impacto del ruido en la matriz de covarianza y evitar errores de inversión.

La Tabla 1 ofrece una perspectiva unificada del estado del arte, clasificando las contribuciones fundamentales de los estudios que han redefinido la arquitectura del modelo.

Tabla 1

Evolución del Modelo HRP (2016-2025)

Paper	Metodología	Objetivo	Resultados
(Lopez de Prado, 2016)	Clustering jerárquico y bisección recursiva.	Introducción del algoritmo HRP para evitar la inversión de la matriz de covarianza.	Reduce inestabilidad numérica y concentración de pesos frente al modelo de Markowitz.
(Raffinot, 2018)	Modelo HERC (Hierarchical Equal Risk Contribution).	Integración del método HCAA para mitigar el problema de encadenamiento.	HERC mejora la asignación de riesgo dentro y entre clusters.
(Sen & Dutta, 2022)	Comparativa HRP vs. Eigen Portfolios en mercados sectoriales.	Evaluación de la consistencia sectorial en análisis fuera de muestra.	HRP supera consistentemente a los enfoques de componentes principales.
(Millea & Edalat, 2023)	Integración de HRP con Deep Reinforcement Learning.	Arquitectura de dos niveles para selección adaptativa de	El sistema muestra robustez superior en mercados heterogéneos y volátiles.

		modelos de riesgo.	
(Salas-Molina et al., 2025)	Evaluación empírica de métricas de distancia en HRP.	Análisis de sensibilidad de métricas basadas en correlación vs. no-correlación.	Demuestra que las métricas de correlación son superiores transversalmente a diversos regímenes de mercado.
(Kang & Tian, 2025)	Aprendizaje por refuerzo y HRP Bayesiano.	Marco unificado que combina estimación bayesiana con control de riesgo dinámico.	Optimiza la distribución del riesgo y maximiza métricas ajustadas al retorno en mercados emergentes.

A pesar de la sofisticación de estas extensiones, la literatura científica presenta una importante brecha de investigación. La mayoría de las variantes de HRP continúan partiendo de matrices de covarianza históricas o lineales que, si bien son ordenadas eficientemente por la estructura jerárquica, siguen siendo afectadas por el ruido de estimación, además de no capturar relaciones subyacentes no lineales desde la etapa de entrada de los datos. Dado lo anterior, surge la oportunidad de complementar el modelo jerárquico con filtros no lineales adaptativos, una necesidad metodológica que adquiere especial relevancia en mercados integrados transfronterizos y con múltiples monedas, caracterizados por quiebres estructurales y dinámicas de codependencia complejas que los optimizadores tradicionales no logran resolver eficazmente.

3. Metodología

3.1 Diseño General del Modelo Propuesto

El Autoencoder Variacional (VAE) es una arquitectura probabilística de aprendizaje no supervisado basada en redes neuronales artificiales, diseñada para aprender representaciones latentes de baja dimensionalidad a partir de datos de alta dimensión (Kingma & Welling, 2019). La arquitectura de un VAE consta de un *encoder* paramétrico que transforma los datos de entrada en los parámetros de una distribución de probabilidad definida en un espacio latente de menor dimensión (Z), y un *decoder* que, a partir de muestras extraídas de dicha distribución, reconstruye los datos originales (Kingma & Welling, 2022). Utilizada en la construcción de portafolios, esta arquitectura fuerza a capturar las dependencias latentes entre los activos al representar los mismos en un espacio de menor dimensionalidad donde el ruido es mitigado, lo que potencialmente favorece la identificación de estructuras de dependencia más estables para el proceso de asignación de activos.

Sea ($X \in R^{n \times T}$) la matriz de retornos correspondiente a un universo de (n) activos en una ventana temporal de (T) períodos. Para cada ventana temporal, el encoder transforma los retornos observados en los parámetros de una distribución latente de dimensión (k), donde (k) representa el número de variables latentes utilizadas para modelar la distribución conjunta de los retornos del universo de activos y satisface ($k \ll n$).

El encoder genera los parámetros (μ) y ($\log \sigma^2$), que definen una distribución gaussiana latente de dimensión (k). A partir de estos parámetros, se obtienen representaciones latentes mediante el muestreo estocástico de la distribución ($Z \sim N(\mu, \sigma^2)$). Por su parte, el decoder reconstruye los retornos originales a partir de las muestras extraídas del espacio latente, de modo que, $\widehat{X} = D_\theta(Z)$.

La reducción de dimensionalidad permite que el modelo funcione como un modelo factorial no lineal de variables latentes estocásticas. Al comprimir la información de los (n) activos en un espacio latente de dimensión (k), la red captura patrones de dependencia comunes entre los activos, lo que potencialmente contribuye a mitigar el efecto del ruido presente en los datos.

Los parámetros del modelo (θ y ϕ) se obtienen mediante la optimización del Límite Inferior de la Evidencia (ELBO) (Kingma & Welling, 2019). Este proceso consiste en minimizar el error de reconstrucción esperado, penalizado por la divergencia de Kullback-Leibler (Kullback & Leibler, 1951), la cual regulariza el espacio latente al inducir que la distribución aproximada tienda hacia una distribución normal multivariada.

$$\arg\min_{\phi,\theta} L(\phi, \theta)$$

$$L = -E_{q_\phi(Z|X)}[\log p_\theta(X|Z)] + KL\left(q_\phi(Z|X) \parallel N(0, I_k)\right) \quad (6)$$

Donde ($q_\phi(Z|X)$) representa la distribución variacional aprendida por el encoder, $\left(p_\theta(X|Z)\right)$ corresponde a la distribución de reconstrucción parametrizada por el decoder y $\left(KL(\cdot)\right)$ denota la divergencia de Kullback-Leibler entre la distribución latente aprendida y el prior gaussiano multivariado $N(0, I_k)$. Los parámetros (ϕ y θ) corresponden a los pesos optimizables del encoder y del decoder, respectivamente.

Aunque el VAE introduce estocasticidad en el espacio latente, la arquitectura propuesta en este estudio incorpora una estrategia de perturbación estocástica de las entradas mediante *dropout* (Srivastava et al., 2014). Con una probabilidad (p_{drop}), los retornos de entrada se establecen aleatoriamente en cero antes de ingresar al encoder, favoreciendo el aprendizaje de representaciones latentes más robustas y mejorando la capacidad de generalización del modelo.

3.2 Reconstrucción de la Matriz de Covarianza

El marco clásico de la Optimización de Media-Varianza (MVO) (Markowitz, 1952) requiere la inversión de la matriz de covarianza para determinar los pesos que minimizan la varianza del portafolio. Cuando el número de activos (n) se aproxima o excede el número de observaciones (T), la matriz de covarianza muestral puede volverse singular o estar mal condicionada, lo que hace que su inversión sea numéricamente inestable (Lopez de Prado, 2016). Como consecuencia, pequeños errores de estimación en la matriz de covarianza pueden producir cambios significativos en el vector de pesos óptimos, provocando, por una parte, la inestabilidad del portafolio y, por otra, un desempeño deficiente fuera de muestra (Michaud, 1989).

Al proyectar el espacio de retornos de los (n) activos sobre una distribución de probabilidad definida en un espacio latente de dimensión (k), los VAE tienden a capturar las estructuras de dependencia más persistentes entre los activos. La restricción impuesta por el cuello de botella latente favorece la representación de los componentes sistemáticos de la covarianza, mientras que la influencia del ruido de estimación tiende a atenuarse. Como resultado, la matriz de covarianza reconstruida podría ser menos sensible a fluctuaciones idiosincráticas y presentar propiedades numéricas más favorables para su inversión, lo que potencialmente contribuiría a obtener participaciones más estables y consistentes con la estructura subyacente de riesgo.

Dado que las distintas inicializaciones aleatorias de los parámetros del modelo pueden conducir a estimaciones de covarianza ligeramente diferentes, aun cuando se utilicen los mismos datos e hiperparámetros, la metodología propuesta emplea una técnica de ensamble profundo (Deep Ensemble) (Lakshminarayanan et al., 2017), compuesta por modelos independientes (M = 20) que permite mitigar este efecto.

Cada miembro se inicializa con una semilla diferente, manteniendo los hiperparámetros óptimos identificados mediante búsqueda bayesiana en la partición de validación correspondiente. Posteriormente cada modelo se entrena de forma independiente. La estimación final de la matriz de covarianza se obtiene como el promedio aritmético de las (M) matrices individuales. Este procedimiento reduce la sensibilidad de las estimaciones a realizaciones particulares del proceso de optimización y favorece una representación más estable de la estructura de dependencia entre activos.

3.3 Validación Walk-Forward

Dado que el VAE define una distribución posterior aproximada, ($q_\phi(Z|X)$), cada observación de entrada induce una distribución sobre reconstrucciones y, en consecuencia, sobre matrices de covarianza. La esperanza de dicha distribución no es tratable de forma analítica dado que el decoder es una función no lineal, por lo que se emplea simulación de Monte Carlo (Robert & Casella, 2004).

Para cada partición, el encoder procesa la última observación de cada ventana de entrenamiento y devuelve los parámetros de la distribución posterior aproximada, (μ y $\log \sigma^2$), para cada observación ($t \in \mathbb{R}^n$). A continuación, se generan (S=250) muestras del espacio latente mediante la técnica de reparametrización.

Cada muestra (z_s) se decodifica para obtener una reconstrucción en espacio estandarizado, la cual se transforma nuevamente al espacio de retornos utilizando la media y la desviación estándar de la última ventana de entrenamiento. La matriz de covarianza Monte Carlo del miembro (m) del ensemble se estima como el promedio de las matrices de covarianza muestrales calculadas sobre las (S) realizaciones simuladas:

$$\hat{\Sigma}_{MC} = \frac{1}{S}\sum_{s=1}^{S} \mathrm{Cov}(\hat{r}^{(s)}) \tag{7}$$

Donde ($\hat{r}^{(s)}$) en ($\mathbb{R}^{T\times n}$) representa la matriz de retornos reconstruidos correspondiente a la realización (s) y ($\mathrm{Cov}(\cdot)$) denota el operador de covarianza muestral.

Dado que el decoder proyecta un espacio latente de (k) dimensiones sobre el espacio original de (n) dimensiones, la matriz de covarianza estimada presenta como máximo rango (k) y, por consiguiente, es singular cuando (k<n). Para obtener una matriz de covarianza de rango completo en cada simulación, se emplea la descomposición aproximada de modelo factorial propuesta por Chamberlain y Rothschild (1983):

$$\Sigma_{Completa} = \Sigma_{VAE} + \mathrm{diag}\left(\Sigma_{Empírica} - \Sigma_{VAE}\right) \tag{8}$$

Donde diag (·) extrae la diagonal, limita los valores negativos a cero y construye la matriz diagonal correspondiente. Esta metodología agrega de nuevo la varianza individual de cada activo eliminada en la compresión, descomponiendo la covarianza total en una componente sistemática de bajo rango y una diagonal de componentes individuales. La matriz resultante es de rango completo por reconstrucción y su inversa matemáticamente está bien definida.

4. Diseño Empírico

4.1 Cálculo de retornos

Se emplean retornos logarítmicos calculados a partir de los precios de cierre diarios de los activos de la muestra. Los retornos se obtienen de la siguiente manera:

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) \tag{9}$$

4.2 Ventanas de Entrenamiento y Evaluación

Todas las operaciones de procesamiento se realizan dentro de una ventana móvil de 60 días de negociación consecutivos, un horizonte seleccionado para capturar las dinámicas y regímenes de mercado de corto sin incurrir en un sobreajuste del modelo (Ma et al., 2023). Cada ventana contiene las observaciones correspondientes al conjunto completo de activos durante dicho período

y constituye la unidad de entrada utilizada para el entrenamiento y evaluación del Autoencoder Variacional (VAE).

Bajo este enfoque, todas las transformaciones y procedimientos de preprocesamiento se ejecutan exclusivamente con la información contenida en la ventana vigente, evitando la incorporación de información futura en el proceso de estimación. El uso de métricas calculadas sobre muestras más amplias introduce un sesgo de anticipación *(look-ahead bias)*, afectando la validez de la evaluación fuera de muestra y generando ponderaciones de portafolio que no serían replicables en condiciones reales de negociación.

4.3 Preprocesamiento robusto de retornos

La primera transformación aplicada a cada ventana consiste en una winsorización basada en la Mediana de la Desviación Absoluta (MAD), utilizando un umbral de cinco veces la MAD (Ma et al., 2023). Para cada activo (i), se calculan la mediana de sus retornos ($\tilde{r}_i$) y la correspondiente medida robusta de dispersión (MAD_i), definida como $\text{mediana}\left(\left|r_{t,i} - \tilde{r}_t\right|\right)$. A partir de estos estadísticos, el retorno winsorizado ($r_{t,i}^{clip}$) se calcula de la siguiente manera:

$$r_{t,i}^{clip} = \text{clip}\left(r_{t,i}, \tilde{r}_i \pm 5 \times MAD_i\right) \tag{10}$$

Este procedimiento reduce la influencia de observaciones extremas presentes en los retornos sin eliminar información de la muestra. Para evitar sesgos de anticipación, los estadísticos de winsorización (mediana y MAD) se estiman exclusivamente sobre cada ventana de entrenamiento y se aplican posteriormente a las ventanas de validación y prueba sin recalibración, evitando así la incorporación de información futura en el proceso de estimación.

4.4. Estandarización

El siguiente paso consiste en estandarizar los retornos de cada activo dentro de la ventana correspondiente mediante una transformación de media cero y varianza unitaria. La transformación se define como:

$$\tilde{r}_{i,t} = \frac{r_{i,t} - \mu_i}{\sigma_i + \epsilon} \tag{11}$$

Donde (μ_i y σ_i) representan la media y la desviación estándar de los retornos del activo (i) en la ventana correspondiente, respectivamente, mientras que ($\epsilon = 1 \times 10^{-8}$) corresponde a un término de estabilidad numérica incorporado para evitar divisiones por cero cuando la volatilidad observada es nula o cercana a cero.

4.5 Esquema de entrenamiento Walk-Forward

El marco de evaluación emplea un protocolo *Walk-Forward* con rebalanceo trimestral, en el cual la frontera entre los conjuntos de entrenamiento y prueba avanza un trimestre en cada iteración, evitando la utilización de información futura. Para el VAE, la ventana de entrenamiento es expansiva y acumula todas las observaciones disponibles hasta el trimestre correspondiente, incorporando una ponderación temporal exponencial de 0.995 que asigna menor peso a las observaciones más antiguas. En contraste, los modelos base empíricos se estiman mediante una ventana rodante fija de 252 días de negociación sin ponderación temporal. Este esquema preserva la estructura temporal de los datos y constituye una práctica ampliamente utilizada para la evaluación fuera de muestra en series financieras (Hyndman & Athanasopoulos, 2018; Racine, 2000).

4.6 Optimización de bayesiana de hiperparámetros

La búsqueda de hiperparámetros del VAE se realiza mediante optimización bayesiana utilizando el algoritmo Tree-structured Parzen Estimator (TPE), implementado a través de la librería Optuna (Akiba et al., 2019), con un total de 15 iteraciones por pliegue *(fold)*. Los hiperparámetros optimizados, junto con sus respectivos espacios de búsqueda y distribuciones de muestreo, se presentan en la Tabla 2. El proceso de optimización se lleva a cabo exclusivamente sobre los conjuntos de entrenamiento y validación del fold correspondiente, preservando el aislamiento completo de las observaciones del período de prueba.

Tabla 2

Espacio de búsqueda y configuración de los hiperparámetros del VAE

Hiperparámetro	Espacio de búsqueda	Tipo
Tasa de dropout (p_{drop})	$0.05 - 0.40$	Continuo (uniforme)
Tasa de aprendizaje	$1 \times 10^{-4} - 1 \times 10^{-2}$	Continuo (log-uniforme)
Penalización de pesos (weight decay)	$1 \times 10^{-6} - 1 \times 10^{-3}$	Continuo (log-uniforme)
Factor de ponderación (KL β)	$1 \times 10^{-5} - 1 \times 10^{-2}$	Continuo (log-uniforme)

La arquitectura del VAE permanece fija durante el proceso de optimización, utilizando una capa oculta de 32 unidades en el encoder con función de activación Tanh y una dimensión latente ($k_z = 8$). Para mejorar la eficiencia computacional, se emplea el algoritmo MedianPruner de Optuna. Tras un mínimo de cinco ensayos completos y un período de calentamiento de diez épocas, los ensayos cuyo desempeño de validación resulta inferior al valor mediano observado en la misma época son terminados anticipadamente. Este mecanismo de poda se inicializa desde cero en cada fold para evitar la transferencia de estado entre períodos de evaluación.

4.7 Metodología de Evaluación

La evaluación del modelo VAE-HRP se realiza mediante un protocolo Walk-Forward que replica la secuencia de decisiones observada en un proceso real de gestión de portafolios. En cada iteración, el flujo completo de preprocesamiento, entrenamiento del VAE, optimización bayesiana de hiperparámetros y construcción de portafolios se ejecuta utilizando exclusivamente la información disponible antes del inicio del horizonte de prueba. Para evaluar el desempeño fuera de muestra, se consideran simultáneamente cinco estrategias de asignación de portafolio:

- **VAE-MV (Mínima Varianza VAE):** Estrategia de mínima varianza construida a partir de la matriz de covarianza de rango completo estimada por el VAE, incluyendo la restauración de la varianza idiosincrática.
- **VAE-HRP:** Estrategia de paridad de riesgo jerárquica (Hierarchical Risk Parity) aplicada a la misma matriz de covarianza estimada por el VAE.
- **MV Clásica:** Estrategia de mínima varianza construida a partir de la matriz de covarianza muestral estimada mediante una ventana rodante fija de 252 días de negociación.
- **HRP Clásico:** Estrategia de paridad de riesgo jerárquica aplicada a la misma matriz de covarianza muestral estimada mediante una ventana rodante fija de 252 días de negociación.
- **Equiponderada (1/N):** Estrategia de asignación uniforme de pesos entre todos los activos, utilizada como *benchmark* de referencia.

La serie de retornos fuera de la muestra (*out-of-sample*, OOS) se construye mediante el encadenamiento cronológico de los retornos obtenidos en cada fold. Este procedimiento preserva la secuencia temporal de las decisiones de inversión y contribuye a mitigar sesgos de anticipación, selección de régimen y sobreajuste durante la evaluación. El desempeño de las estrategias se evalúa y compara mediante las métricas de rendimiento, riesgo y actividad transaccional presentadas en la Tabla 3.

Tabla 3

Métricas de evaluación de desempeño, riesgo y actividad transaccional de los portafolios

Métrica	Definición
Retorno Total (TOR)	Retorno acumulado del periodo OOS (out-of-sample) completo
Ratio de Sharpe (SR)	Exceso de retorno anualizado dividido entre la SD, utilizando una tasa libre de riesgo de 4.62%
Desviación Estándar Anualizada (SD)	Desviación estándar anualizada de los retornos del portafolio
Máximo Drawdown (MD)	Rendimiento acumulado máximo desde el pico más alto hasta el valle más bajo

Número Efectivo de Activos (ENA)	Medida de diversificación definida como el inverso del índice de Herfindahl-Hirschman de las ponderaciones del portafolio, promediada sobre todos los trimestres evaluados
Rotación Promedio del Portafolio (Turnover)	Cambio absoluto medio en las ponderaciones de los activos entre rebalanceos trimestrales consecutivos

5. Datos

La muestra de activos seleccionada para este estudio corresponde a las acciones que conforman el índice MSCI NUAM, el cual sintetiza la integración de los mercados bursátiles de Chile, Colombia y Perú a través de sus firmas más representativas (MSCI, 2026). Las series históricas recopiladas comprenden los precios diarios de cierre en una ventana temporal que se extiende desde el 28 de junio de 2019 hasta el 13 de abril de 2026.

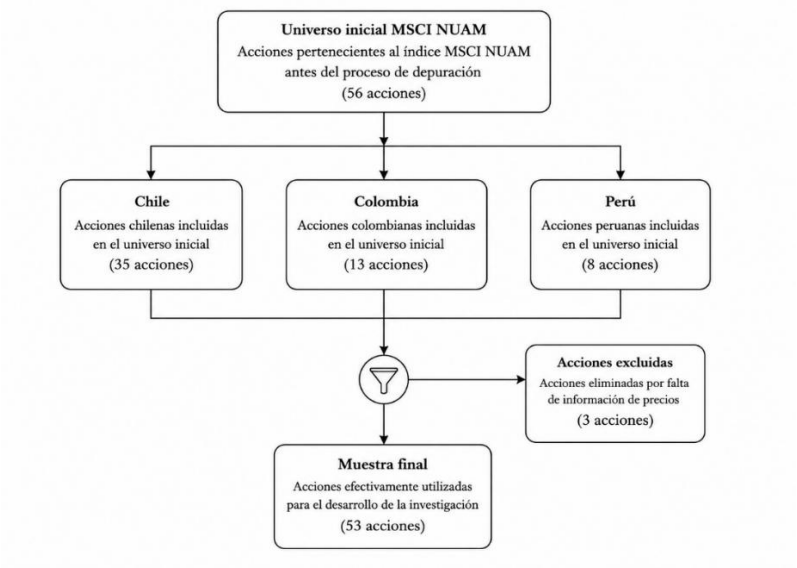
La delimitación de este horizonte temporal responde a la necesidad de evaluar el desempeño del algoritmo propuesto bajo regímenes de mercado heterogéneos. La muestra captura la fase previa a la crisis del COVID-19, el estrés financiero global observado durante 2020, el ciclo de recuperación de los mercados en 2021 y 2022, y un entorno macroeconómico condicionado por el endurecimiento de la política monetaria global, presiones inflacionarias y tensiones geopolíticas.

5.1 Criterios de Inclusión y Filtrado

Con el fin de garantizar la consistencia de la base de datos y la disponibilidad de información para todo el periodo de análisis, se realizó un proceso de filtrado sobre el universo inicial. El criterio de exclusión ejecutado fue la ausencia de registros de precios para la totalidad del horizonte temporal del estudio. Como resultado, se retiraron tres acciones que no cumplían con la ventana completa, consolidando una muestra final de 53 acciones. El flujo de depuración se presenta en la Figura 1.

Figura 1

Flujo de depuración y selección de la muestra



5.2 Análisis de Diversificación Geográfica y Sectorial

La muestra final permite ver una distribución asimétrica pero representativa de la profundidad financiera regional: 34 acciones pertenecen al mercado chileno (64,2%), 12 al colombiano (22,6%) y 7 al peruano (13,2%).

En la Tabla 4 se evidencia que el sector financiero actúa como el componente predominante de la muestra con 16 activos, seguido por los segmentos de materiales (9 activos) y servicios públicos (8 activos). El resto de los títulos se distribuye entre actividades asociadas a consumo básico y discrecional, industria, tecnología, energía, comunicaciones e infraestructura inmobiliaria. Esta heterogeneidad provee la variabilidad estructural requerida para que el modelo propuesto (VAE-HRP) aísle el ruido idiosincrásico dentro del mercado estudiado.

Tabla 4

Selección de acciones

Sector	Chile	Colombia	Perú	Número de acciones
Servicios de comunicación	Entel			1
Consumo Discrecional	Falabella, Ripley, Forus			3
Consumo básico	Cencosud, Andina, CCU, SMU, Concha y Toro		Alicorp	6
Energía		Ecopetrol		1

Financiero	Banco de Chile, Santander Chile, BCI, Itaú Chile, Quiñenco, ILC, Banco BICE	Grupo Cibest, Grupo Cibest Preferencial, Grupo Sura, Grupo Sura Preferencial, Grupo Aval, Davivienda Preferencial, Corficolombiana	Credicorp, Intercop Financial Services	16
Industrial	LATAM Airlines, Empresas Copec, Vapores, SalfaCorp		Ferreycorp	5
Tecnología de la información	Sonda			1
Materiales	SQM, CMPC, CAP, Oro Blanco	Grupo Argos, Cementos Argos	Southern Copper, Buenaventura, Volcan	9
Inmobiliario	Mallplaza, Parque Arauco, Cencosud Shopping			3
Servicios públicos	Enel Américas, Enel Chile, Colbún, Aguas Andinas, Engie Chile, IAM	ISA, Celsia		8
Número de acciones				**53**

6. Resultados

La Tabla 5 presenta el desempeño fuera de muestra del portafolio de referencia basado en la Paridad de Riesgo Jerárquica estándar (HRP Clásico) y de la extensión propuesta en esta investigación (VAE-HRP) para el mercado integrado NUAM. La comparación considera seis métricas utilizadas para evaluar simultáneamente el rendimiento ajustado por riesgo, la volatilidad de los retornos, la magnitud de las pérdidas acumuladas, la rotación del portafolio y el grado de diversificación de las asignaciones. Estas métricas permiten examinar tanto el desempeño financiero como las características operacionales asociadas al proceso de construcción de portafolios.

Tabla 5

Comparación del desempeño fuera de muestra entre los portafolios HRP Clásico y VAE-HRP en el mercado NUAM.

Métrica	HRP Clásico	VAE-HRP
Retorno Total (TOR)	0.7107	0.7312
Ratio de Sharpe (SR)	0.4938	0.5210
Desviación Estándar Anualizada (SD)	0.1068	0.1056
Máximo Drawdown (MD)	-0.2116	-0.2232
Número Efectivo de Activos (ENA)	21.69	19.65
Rotación Promedio del Portafolio (Turnover)	0.4823	0.4139

La estrategia VAE-HRP exhibe una rotación promedio del portafolio de 0.4139, inferior al valor de 0.4823 observado para el HRP clásico. Este resultado sugiere una mayor estabilidad de las ponderaciones entre períodos consecutivos de rebalanceo, reflejando una menor frecuencia de ajustes en la composición del portafolio. Desde una perspectiva de implementación, una menor rotación podría contribuir a reducir los costos asociados a la actividad transaccional y favorecer una ejecución más estable de estrategias de asignación.

Los resultados muestran una mejora en las métricas de desempeño fuera de muestra. El portafolio VAE-HRP alcanza un Retorno Total acumulado de 0.7312, superior al 0.7107 registrado por el HRP clásico. Por otra parte, el Ratio de Sharpe anualizado aumenta de 0.4938 a 0.5210, mientras que la desviación estándar anualizada se reduce ligeramente de 0.1068 a 0.1056. Estos hallazgos indican que la estrategia propuesta obtiene una relación riesgo-retorno más favorable durante el período de evaluación, combinando mayores retornos acumulados con una menor volatilidad de los rendimientos.

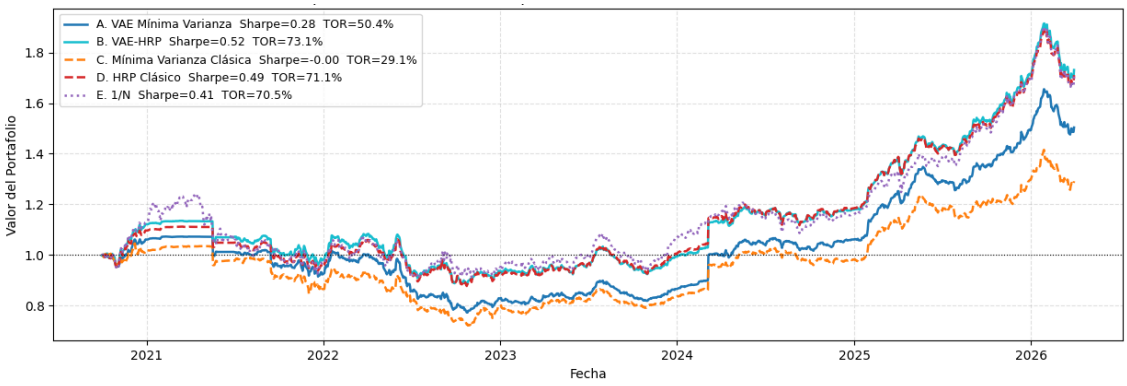
La mejora observada en el desempeño ajustado por riesgo se acompaña de un cambio en la estructura de diversificación del portafolio. El número efectivo de activos disminuye de 21.69 a 19.65, lo que indica una mayor concentración relativa de las asignaciones bajo la estrategia VAE-HRP. De manera consistente, el máximo drawdown observado pasa de menos 0.2116 a menos 0.2232, reflejando una pérdida acumulada máxima ligeramente superior a la registrada por el HRP clásico. Estos resultados sugieren que las ganancias observadas en términos de retorno y eficiencia riesgo-retorno se obtienen a costa de una reducción moderada de la diversificación efectiva y sin mejoras en la pérdida máxima experimentada durante el período fuera de muestra.

La Figura 2 presenta la evolución fuera de muestra del valor acumulado de los portafolios. Si bien los portafolios VAE-HRP y HRP clásico exhiben trayectorias similares durante gran parte del horizonte de evaluación, la estrategia VAE-HRP alcanza un desempeño acumulado superior en la parte final del período fuera de muestra. Esta diferencia es consistente con los resultados reportados en la Tabla 5, donde el modelo propuesto en esta investigación registra un mayor Retorno Total acumulado y un Ratio de Sharpe superior al obtenido por el HRP clásico. Estos

resultados indican una mejora en el desempeño ajustado por riesgo durante el período de evaluación fuera de muestra.

Figura 2

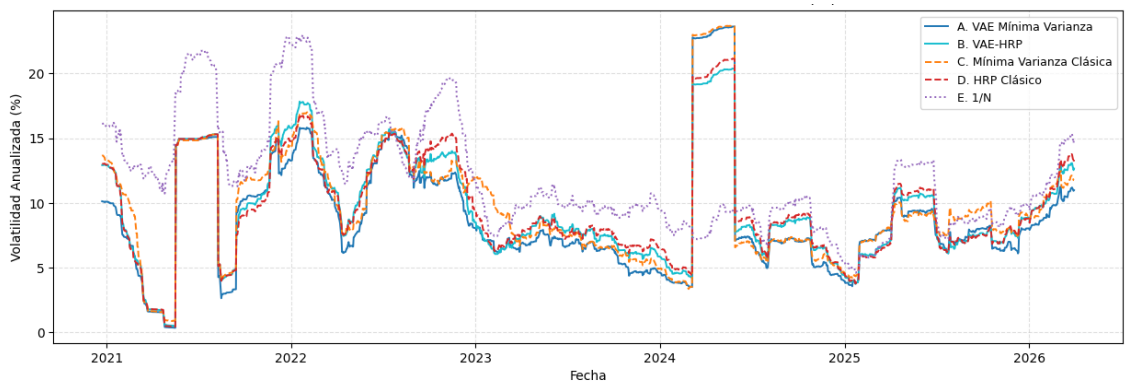
Evolución fuera de muestra del valor acumulado de una inversión inicial de 1 COP bajo las distintas metodologías de construcción de portafolios



La Figura 3 presenta la evolución temporal de la volatilidad anualizada realizada para las distintas estrategias durante el período fuera de muestra. En términos generales, los portafolios HRP clásico y VAE-HRP exhiben trayectorias de riesgo similares a lo largo del horizonte de evaluación, aunque el modelo propuesto registra una volatilidad promedio ligeramente inferior a la observada para el HRP clásico.

Figura 3

Evolución de la volatilidad anualizada realizada durante el período fuera de muestra para las distintas metodologías de construcción de portafolios



7. Conclusiones

La evidencia empírica de esta investigación respalda la incorporación de arquitecturas no lineales como una extensión adecuada para la optimización de portafolios basados en el método de Paridad de Riesgo Jerárquica (HRP) en el contexto analizado. El modelo VAE-HRP propuesto mejora el

desempeño ajustado por riesgo, alcanzando un Ratio de Sharpe anualizado de 0.5210 frente al 0.4938 del modelo HRP clásico. Los resultados sugieren que el uso de representaciones latentes generadas por el autoencoder variacional se relaciona con una mejora del desempeño fuera de muestra.

De este modo, el presente estudio evidencia la conveniencia de complementar el método jerárquico propuesto por Marcos López de Prado con técnicas que permitan capturar relaciones no lineales complejas entre los activos. La mejora observada en el Ratio de Sharpe y en la estabilidad de las asignaciones sugiere que la información extraída por el modelo aporta elementos complementarios a los contenidos en las matrices de covarianza tradicionales utilizadas por el enfoque HRP clásico. Este resultado se refleja en la disminución de la rotación intertemporal del portafolio, que registra un turnover de 0.4139 frente al 0.4823 del modelo clásico. Desde un punto de vista operacional, la menor rotación observada podría traducirse en menores costos de rebalanceo.

Aunque la estrategia propuesta mejora el retorno acumulado y el desempeño ajustado por riesgo, se tiene una mayor concentración relativa de las participaciones de los activos, reflejada en la reducción del Número Efectivo de Activos (19.65 frente a 21.69). Asimismo, el máximo drawdown aumenta ligeramente de −0.2116 a −0.2232. En conjunto, estos resultados sugieren que la mayor eficiencia del binomio riesgo-retorno se obtiene sacrificando algo de diversificación.

La utilidad de la arquitectura aquí planteada se basa en su capacidad para capturar tendencias estructurales que el enfoque lineal no tiene en cuenta, lo que permite mejorar la gestión de portafolios en contextos transfronterizos. Como posibles líneas de investigación, se propone incorporar dinámicas de costos de transacción directamente en el proceso de optimización. Además, se plantea explorar extensiones algorítmicas tales como Autoencoders Condicionales (CVAE) para integrar variables macroeconómicas exógenas, o la implementación de Redes Neuronales de Grafos (GNN), con el fin de evaluar la robustez de la asignación bajo distintos regímenes de mercado.

Declaración sobre el uso de IA

Los autores declaran que emplearon herramientas de inteligencia artificial (IA) generativa en actividades de corrección de estilo, revisión ortográfica y gramatical. Todo el contenido ha sido revisado, corregido y validado por los autores, quienes asumen plena responsabilidad por la exactitud, originalidad y validez de los resultados presentados.

Referencias

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2623–2631. https://doi.org/10.1145/3292500.3330701

Bajpai, S., Sharma, A., Deo, A., & Baniya, M. (2023). Portfolio optimization for Indian mutual funds: A comparative study. *2023 International Conference on Decision Aid Sciences and Applications (DASA)*, 247–251. https://doi.org/10.1109/DASA59624.2023.10286645

Borovkova, S., & van den Oever, M. (2022). *Ariational AutoEncoders with Student-t distribution for large portfolios* (SSRN Scholarly Paper No. 4264976). Social Science Research Network. https://doi.org/10.2139/ssrn.4264976

Chamberlain, G., & Rothschild, M. (1983). Arbitrage, factor structure, and mean-variance analysis on large asset markets. *Econometrica*, *51*(5), 1281–1304. https://doi.org/10.2307/1912275

Ciciretti, V., & Pallotta, A. (2024). Network risk parity: Graph theory-based portfolio construction. *Journal of Asset Management*, *25*(2), 136–146. Springer Nature Journals (edssjs.22870A67). https://doi.org/10.1057/s41260-023-00347-8

Cotton, P. (2024). *Schur complementary allocation: A unification of hierarchical risk parity and minimum variance portfolios* (arXiv:2411.05807). arXiv. https://doi.org/10.48550/arXiv.2411.05807

Deković, D., & Šimović, P. P. (2025). Hierarchical risk parity: Efficient implementation and real world analysis. *Future Generation Computer Systems*, *167*, 107744. https://doi.org/10.1016/j.future.2025.107744

Duan, Y., Wang, L., Zhang, Q., & Li, J. (2022). FactorVAE: A probabilistic dynamic factor model based on variational autoencoder for predicting cross-sectional stock returns. *Proceedings of the AAAI Conference on Artificial Intelligence*, *36*(4), 4468–4476. https://doi.org/10.1609/aaai.v36i4.20369

Gaggero, G., Giribone, P. G., Muselli, M., Ünal, E., & Verda, D. (2024). *Portfolio optimization and risk management through Hierarchical Risk Parity and Logic Learning Machine: A case study applied to the Turkish stock market*. https://doi.org/10.47473/2020rmm0137

Habib, U., Hayat, K., & Zucker, G. (2016). Complex building's energy system operation patterns analysis using bag of words representation with hierarchical clustering. *Complex Adaptive Systems Modeling*, *4*(1), 1–20. Springer Nature Journals (edssjs.F461F57B). https://doi.org/10.1186/s40294-016-0020-0

Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and practice* (2nd ed.). OTexts. https://research.monash.edu/en/publications/forecasting-principles-and-practice-2/

Kaczmarek, T., & Perez, K. (2022). Building portfolios based on machine learning predictions. *Economic Research-Ekonomska Istraživanja*, *35*(1), 19–37. https://doi.org/10.1080/1331677X.2021.1875865

Kang, S., & Tian, Z. (2025). *Optimal portfolio construction: A reinforcement learning embedded Bayesian hierarchical risk parity (RL-BHRP) approach* (arXiv:2508.11856). arXiv. https://doi.org/10.48550/arXiv.2508.11856

Katranci, A., & Kundakci, N. (2026). A novel hybrid portfolio optimization framework: Integrating HRP with MEREC and WEDBA methods. *Informatica*, 1–39. https://doi.org/10.15388/26-INFOR618

Kingma, D. P., & Welling, M. (2019). An introduction to variational autoencoders. *Foundations and Trends® in Machine Learning*, *12*(4), 307–392. https://doi.org/10.1561/2200000056

Kingma, D. P., & Welling, M. (2022). *Auto-Encoding Variational Bayes* (arXiv:1312.6114). arXiv. https://doi.org/10.48550/arXiv.1312.6114

Kolm, P. N., Tütüncü, R., & Fabozzi, F. J. (2014). 60 Years of portfolio optimization: Practical challenges and current trends. *European Journal of Operational Research*, *234*(2), 356–371. ScienceDirect (S0377221713008898). https://doi.org/10.1016/j.ejor.2013.10.060

Kullback, S., & Leibler, R. A. (1951). On information and sufficiency. *The Annals of Mathematical Statistics*, *22*(1), 79–86. https://doi.org/10.1214/aoms/1177729694

Lakshminarayanan, B., Pritzel, A., & Blundell, C. (2017). Simple and scalable predictive uncertainty estimation using deep ensembles. *Advances in neural information processing systems*, *30*.

Lewis, M. J. (2023). *Improved portfolio diversification through unsupervised learning* (SSRN Scholarly Paper No. 4580833). Social Science Research Network. https://doi.org/10.2139/ssrn.4580833

Li, A., Meng, Y., & Wang, P. (2024). Similarity-based three-way clustering by using dimensionality reduction. *Mathematics*, *12*(13), 1951. https://doi.org/10.3390/math12131951

Lopez de Prado, M. (2016). *Building diversified portfolios that outperform out-of-sample* (SSRN Scholarly Paper No. 2708678). Social Science Research Network. https://doi.org/10.2139/ssrn.2708678

Lu, H., & Uddin, S. (2024). Unsupervised machine learning for disease prediction: A comparative performance analysis using multiple datasets. *Health and Technology*, *14*(1), 141–154. https://doi.org/10.1007/s12553-023-00805-8

Ma, Y., Wang, W., & Ma, Q. (2023). A novel prediction based portfolio optimization model using deep learning. *Computers & Industrial Engineering*, *177*, Article 109023. https://doi.org/10.1016/j.cie.2023.109023

Markowitz, H. (1952). Portfolio selection. *The Journal of Finance*, *7*(1), 77–91. https://doi.org/10.1111/j.1540-6261.1952.tb01525.x

Mena Valencia, N. A. (2023). *Modelo de paridad de riesgo jerárquico: Optimización de portafolio multiactivo*. https://hdl.handle.net/10784/32842

Michaud, R. O. (1989). The Markowitz optimization enigma: Is “optimized” optimal? *Financial analysts journal*, *45*(1), 31–42.

Millea, A., & Edalat, A. (2023). Using deep reinforcement learning with hierarchical risk parity for portfolio optimization. *International Journal of Financial Studies*, *11*(1), 1–16. EconLit with Full Text (2080847).

Mograby, G. (2025). *Hierarchical minimum variance portfolios: A theoretical and algorithmic approach* (arXiv:2503.12328). arXiv. https://doi.org/10.48550/arXiv.2503.12328

Montoya, J. C. C. (2024). La integración del mercado bursátil latinoamericano: Una revisión sistemática de la literatura. *Revista Finanzas y Política Económica*, *16*(2), 317–354. https://doi.org/10.14718/revfinanzpolitecon.v16.n2.2024.1

MSCI. (2026). *MSCI NUAM Index*. MSCI. https://www.msci.com/indexes/index-series/msci-nuam-index

Ortiz Mayorga, B. (2025). *Integración de bolsas para América Latina: Perspectivas, oportunidades y retos para Colombia*. https://repositorio.unal.edu.co/handle/unal/89336

Palit, D., & Prybutok, V. R. (2024). A study of hierarchical risk parity in portfolio construction. *Journal of Economic Analysis*, *3*(3), 106–125.

Paolella, M. S., Polak, P., & Walker, P. S. (2025). Risk parity portfolio optimization under heavy-tailed returns and dynamic correlations. *Journal of Time Series Analysis*, *46*(2), 353–377. https://doi.org/10.1111/jtsa.12792

Prado, M. L. de. (2018). *Advances in financial machine learning*. Wiley.

Racine, J. (2000). Consistent cross-validatory model-selection for dependent data: Hv-block cross-validation. *Journal of Econometrics*, *99*(1), 39–61. https://doi.org/https://doi.org/10.1016/S0304-4076(00)00030-0

Raffinot, T. (2018). *The Hierarchical Equal Risk Contribution Portfolio* (SSRN Scholarly Paper No. 3237540). Social Science Research Network. https://doi.org/10.2139/ssrn.3237540

Robert, C. P., & Casella, G. (2004). *Monte Carlo statistical methods* (C. P. Robert & G. Casella, Eds.). Springer. https://doi.org/https://doi.org/10.1007/978-1-4757-4145-2

Rodriguez Dominguez, A. (2023). Portfolio optimization based on neural networks sensitivities from assets dynamics respect common drivers. *Machine Learning with Applications*, *11*, 100447. https://doi.org/10.1016/j.mlwa.2022.100447

Ruiz, D., & Alvarado, C. (2024). Análisis de la integración regional de bolsas de valores: Un enfoque de organización industrial. *Revista Moneda*, (197), 57–63.

Salas-Molina, F., Pla-Santamaria, D., Garcia-Bernabeu, A., & Hilario-Caballero, A. (2025). An empirical evaluation of distance metrics in hierarchical risk parity methods for asset allocation. *Computational Economics*, 1–18. Springer Nature Journals (edssjs.95E80D79). https://doi.org/10.1007/s10614-025-10848-w

Sen, J., & Dutta, A. (2022). *A comparative study of hierarchical risk parity portfolio and eigen portfolio on the NIFTY 50 stocks*. arXiv (edsarx.2210.00984). https://doi.org/10.1007/978-981-19-3391-2_34

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *The journal of machine learning research*, *15*(1), 1929–1958.

Urrego, D. A. (2024). Aplicación del modelo contribución jerárquica de igual riesgo con ADR latinoamericanos. *ODEON*, (25), 55–71. https://doi.org/10.18601/17941113.n25.03

Yokokawa, D., Noda, K., Yanagita, Y., Uehara, T., Ohira, Y., Shikino, K., Tsukamoto, T., & Ikusaka, M. (2022). Validating the representation of distance between infarct diseases using word embedding. *BMC Medical Informatics and Decision Making*, *22*(1), 322. https://doi.org/10.1186/s12911-022-02061-8